ARTÍCULO ENVIADO

¿Cómo Netflix conoce tus gustos?

José E. Rojas-Macedo y Ángel Hernández-Castañeda

Introducción

Dentro de la era digital, la personalización de servicios se ha convertido en una característica esencial para ofrecer una experiencia de usuario (UX) superior. Desde las plataformas de streaming, hasta algunos *e-commerce*, utilizan sistemas de recomendación que nos ofrecen contenido, productos o servicios basados en nuestros gustos. ¿Cómo se logra esto? La respuesta está en el uso de algoritmos de recomendaciones.

Uno de los más utilizados, es el filtrado colaborativo (FC), una técnica que permite que plataformas como Netflix, Amazon o Spotify ofrezcan contenido basado en lo que personas con gustos similares han disfrutado. En este artículo, se explorará una aproximación simple de cómo se construyen estos sistemas, de qué forma se entrenan y cómo se pueden desarrollar usando Python y la librería de Surprise.

El algoritmo detrás de las recomendaciones

Un algoritmo representa una secuencia de instrucciones precisas que permiten resolver un problema o ejecutar una tarea específica, como la receta para preparar un pastel. En los sistemas de recomendación, el algoritmo recibe como entrada un conjunto de datos, en este caso, puede incluir las películas que has visto y las valoraciones que has dado sobre el contenido. Con dicha información, el algoritmo busca patrones entre tus datos y los de miles o millones más para sugerir nuevos elementos.

En un nivel básico, el FC cuenta con dos enfoques o métodos:

1. **Basado en usuarios:** Encuentra usuarios que tengan preferencias similares a un usuario para recomendarle películas que estos hayan disfrutado.
2. **Basado en elementos:** Encuentra películas que tengan características similares a las que un usuario ha disfrutado para recomendarle otras similares.

En ambos casos, los algoritmos buscan patrones en los datos que pueden ser aprovechados para generar recomendaciones acertadas. Durante los últimos años, el filtrado colaborativo ha evolucionado con la integración de técnicas más avanzadas como la **Descomposición de Valores Singulares** (SVD) o **Factorización de Matrices** (MF), que permiten mejorar la precisión de las recomendaciones.

Para este artículo, se utilizó el enfoque basado en usuarios, el cual, como se mencionó, analiza las preferencias de los usuarios para determinar qué películas sugerir a cada persona. La ventaja de usar este enfoque es que, a diferencia del basado en elementos, este se basa en la experiencia de otros usuarios para hacer recomendaciones (ver Figura 1).

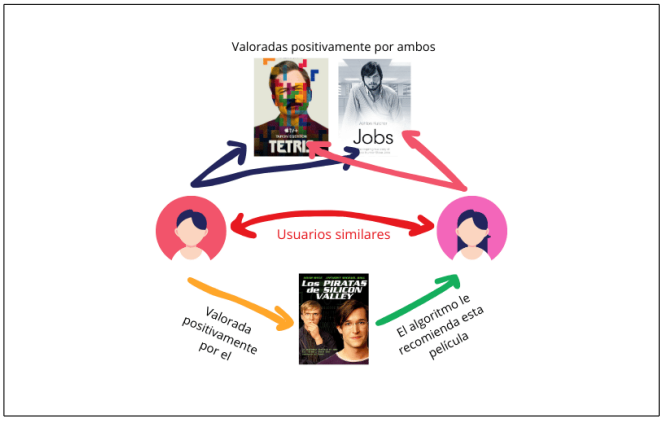

Figura 1. Funcionamiento del filtrado colaborativo basado en usuarios

El filtrado colaborativo utiliza datos de múltiples usuarios para ofrecer recomendaciones personalizadas.

Metodología

Esta sección describe cómo se construyo el sistema de recomendación utilizando Python y la librería de Surprise:

1. **Importación de datos:** Se utiliza un conjunto de datos de películas que incluye información sobre los usuarios, películas y valoraciones de los usuarios por película.
2. **Preprocesamiento de datos:** Los datos son limpiados y transformados en un formato adecuado para el entrenamiento del modelo. Para este proceso se usan las librerías de Pandas y Numpy.

3. **Entrenamiento del modelo:** Con la biblioteca Surprise se desarrolla el modelo, para ello, se utiliza la técnica de SVD. Este algoritmo descompone la matriz de las valoraciones de los usuarios en factores que representan las características de los usuarios y de las películas, para así generar recomendaciones más precisas.

4. **Evaluación del modelo:** El rendimiento del modelo se evalúa utilizando la métrica *RMSE (Root Mean Squared Error)*, la cual, mide la diferencia entre las predicciones del modelo y las valoraciones reales de los usuarios.

5. **Generación de recomendaciones:** Se generan recomendaciones para un usuario específico mediante una función que manda a llamar al modelo de filtrado colaborativo.

Importación de datos

Como primer paso para la construcción de un sistema de recomendación, es necesario disponer de un conjunto de datos adecuado para el análisis y entrenamiento del algoritmo.

En este sentido, se utilizó un conjunto de datos de películas que incluye información sobre los usuarios, películas y valoraciones de los usuarios por película. El conjunto es una versión ligera de toda la base de datos de *MovieLens*, una plataforma de recomendación de películas, que incluye alrededor de 100,000 valoraciones de 600 usuarios aplicadas a 9,000 películas hasta 2018 y que cuenta con alrededor de 3,600 etiquetas, compuesto de 4 archivos CSV: *ratings.csv*, *movies.csv*, *links.csv* y *tags.cvs*, de los cuales se utilizaron solamente los dos primeros.

La necesidad de ILNBDs se ha incrementado últimamente, debido a que, con el crecimiento de las tecnologías, muchos usuarios solicitan acceder a la información (contenida en BDs) desde diferentes tipos de sistemas, tales como: computadoras, celulares, PDAs (por sus siglas en inglés, Personal Digital Assistants), etc. Incluso, el magnate de la computación, Bill Gates, afirmó: "las interfaces de lenguaje natural dominarán el desarrollo de las computadoras personales en la nueva década" [2][3].

Limitaciones

Las interfaces de lenguaje natural para acceder a BDs han sido utilizadas desde finales de los 60s y principios de los 70s. Aunque se han desarrollado una gran cantidad de ILNBDs desde entonces, las limitaciones y deficiencias que poseen son de llamar la atención. Algunas ILNBDs comerciales ilustran esta situación; por ejemplo, LanguageAccess fue descontinuado por IBM; English Query (desarrollado por Microsoft) fue incluido por última vez en SQL Server ver. 8.0, liberado en el año 2000; English Wizard (desarrollado por Linguistic Technology Corporation) fue descontinuado hace algunos años; y finalmente, uno de los más exitosos, Access English Language Front End (ELF) desarrollado por ELF Software Co., aunque continúa su distribución la compañía ya no existe.

El desempeño de una ILNBD esta ligado con la configuración de dominio, entre mejor configurado se encuentre, mayor es el entendimiento de las consultas por parte de la interfaz.

La mayoría de los usuarios de ILNBDs consideran que los sistemas existentes son bastante robustos y precisos, pero esta evaluación es relativa; las ILNBDs que han obtenido buenos resultados (alrededor del 95 % de consultas correctamente traducidas) son de dominio específico —es decir, aquéllas que únicamente pueden consultar una sola BD— mientras que las independientes de dominio —es decir, aquéllas que pueden usarse para consultar diferentes BDs— continúan teniendo deficiencias en el proceso de traducción (con una tasa de éxito entre el 80-90 %).

Con respecto a la independencia de dominio, un factor que ha limitado el uso de las ILNBDs ha sido la dificultad para configurar dichos sistemas a una BD en particular, a menudo los administradores de BDs necesitan altos niveles de experiencia y llevan a cabo esta tarea empleando un largo tiempo de configuración [5].

Las ILNBDs que ofrecen independencia de dominio necesitan un proceso inicial de configuración antes de que los usuarios finales puedan introducir sus consultas. La configuración consiste en proporcionar al sistema las palabras y conceptos necesarios para el dominio (llamado también diccionario de datos o de dominio), el cual está relacionado con la información almacenada en la BD.

Aunque algunas ILNBDs cuentan con mecanismos sencillos de configuración, desafortunadamente las configuraciones iniciales solamente tienen un buen desempeño con BDs pequeñas y su desempeño es insatisfactorio para BDs más grandes. En muchos casos se puede modificar la configuración inicial para mejorar el desempeño, pero esta tarea suele ser compleja, tediosa y requiere una profunda comprensión del funcionamiento de la interfaz.

Algunos de los principales problemas encontrados en el proceso de traducción están relacionados con:

1. el uso de palabras o sintagmas de diferentes cate-

gorías sintácticas para referirse a tablas y columnas de la BD (tales como sustantivos, verbos, adjetivos, y preposiciones),

2. la elipsis semántica, que ocurre cuando se omiten palabras que son necesarias para el claro entendimiento de la consulta,

3. la capacidad de cobertura de SQL, como el uso de varias tablas de la BD y el uso de funciones de agregación, y

4. otro tipo de problemas que involucran errores humanos, tales como, información no existente en la BD, palabras que indican valores imprecisos, etc.

La investigación sobre ILNBDs continúa siendo un problema de investigación abierto por el simple hecho de que ninguna interfaz ha logrado realizar el proceso de traducción totalmente correcto.

Antecedentes

Los primeros sistemas de consulta en lenguaje natural fueron desarrollados en los 60s, y principalmente eran interfaces de lenguaje natural para sistemas expertos, diseñados para funcionar en dominios específicos. Sólo podían ser usados en una BD particular, por lo cual era difícil modificarlos para consultar diferentes BDs.

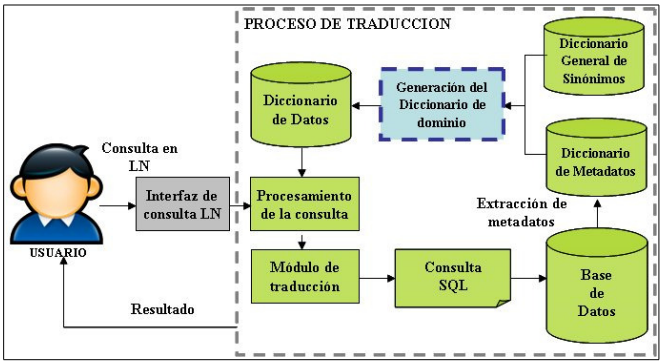

Figura 2. Arquitectura de la primera versión de la ILNBD desarrollada

El auge del desarrollo de ILNBDs se produjo en los años 80s. A pesar de la implementación de muchos sistemas en ese entonces, poco a poco fue disminuyendo su uso debido a varios problemas que afectan su desempeño.

Existen muchas ILNBDs desarrolladas en las últimas dos décadas, la mayoría son para idiomas extranjeros, sobre todo inglés. Para conocer más detalles acerca del estado del arte de ILNBDs, se recomienda consultar [6].

En idioma español existen muy pocos trabajos en ILNBDs, por lo cual nos encontramos desarrollando una ILNBD que forma parte de un proyecto denominado "Interfaz de Lenguaje Natural Español hacia Bases de Datos para Usuarios de Internet", el cual comenzó a desarrollarse en el Centro Nacional de Investigación y Desarrollo Tecnológico (CENIDET) desde el año 2001 y se ha continuado en el Instituto Tecnológico de Ciudad Madero (ITCM) desde el año 2002 hasta la fecha. Dicho proyecto tiene como fin implementar una interfaz que permita a usuarios casuales e inexpertos consultar BDs mediante expresiones en lenguaje español no acotado.

Una característica importante de esta ILNBD es su independencia de dominio; es decir, su capacidad para interactuar con BDs de diferentes dominios. En la siguiente sección se describiren las aportaciones que se han realizado en el desarrollo de nuestra ILNBD.

Aportaciones

Como se mencionó anteriormente, este trabajo forma parte de un proyecto iniciado en el año 2001, desde entonces han sido implementadas dos versiones de la ILNBD, y se encuentra en proceso el desarrollo de una nueva versión. A continuación se mencionarán las contribuciones realizadas.

La primera versión de la interfaz fue desarrollada por CENDIDET-ITCM [7]. Utiliza un método para la traducción de consultas en español a SQL, lo cual permite a los usuarios realizar consultas a una BD sin necesidad de configuraciones tediosas. El manejo de la independencia del dominio es la característica principal de esta interfaz, y para lograrlo utiliza un preprocesador que genera automáticamente un diccionario de dominio y una técnica de traducción que utiliza sustantivos (que hacen referencia a tablas o columnas de la BD), y preposiciones y conjunciones, ya que estas últimas mantienen el significado en cualquier contexto y no necesitan ser configuradas para un dominio particular.

En dicho trabajo se construye el diccionario de dominio (o diccionario de datos) para la interfaz de forma automática a partir de: 1) un diccionario de sinónimos (que sirve al etiquetador gramatical para relacionar sinónimos de las palabras de la consulta), 2) un etiquetador gramatical (que etiqueta las palabras de la consulta), y 3) un diccionario de metadatos (el cual contiene información estructural de la BD).

El módulo de traducción consta de tres fases:

1. La separación de las frases Select y Where, que consiste en la división de la consulta en las partes que correspondan a los requerimientos y a las condiciones de búsqueda. Las preposiciones y conjunciones son representadas como operaciones usando la teoría de conjuntos.

2. La identificación de tablas y columnas, en la cual se pueden relacionar las tablas y las columnas con los sustantivos que se encuentran en la consulta.

3. La construcción del grafo relacional, en donde se

establecen las relaciones entre las tablas que fueron mencionadas en la consulta.

Después de este procesamiento, se realiza la conversión de la información encontrada a una consulta SQL, para ser ejecutada y enviar los resultados al usuario. En la Figura 2, se muestra la arquitectura simplificada de la primera versión de la ILNBD desarrollada.

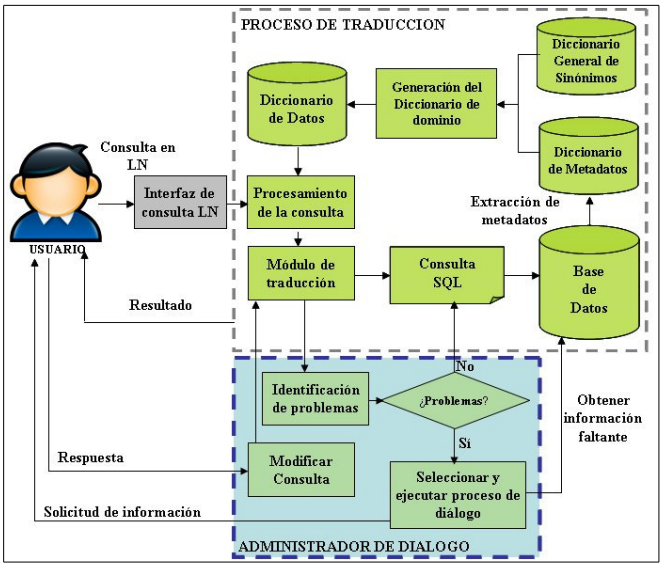

Figura 3. Arquitectura de la ILNBD con administrador de diálogo

A pesar del buen desempeño que tiene esta interfaz, no permite al usuario un diálogo de aclaración cuando la consulta no puede ser traducida (es decir, si la consulta tiene problemas de elipsis semántica), lo cual limita su capacidad para obtener un mayor porcentaje de aciertos en las consultas traducidas.

Posteriormente se continuó con la mejora de este trabajo en [8], en el cual la propuesta principal fue implementar procesos de diálogo independientes del dominio para un administrador de diálogo para la ILNBD. Para lograr que los diálogos tuvieran las características anteriormente mencionadas, se formalizó una tipificación de problemas en consultas que permite abarcar la mayoría de los casos, de esta manera fueron implementados los procesos de diálogo correspondientes a los problemas tipificados.

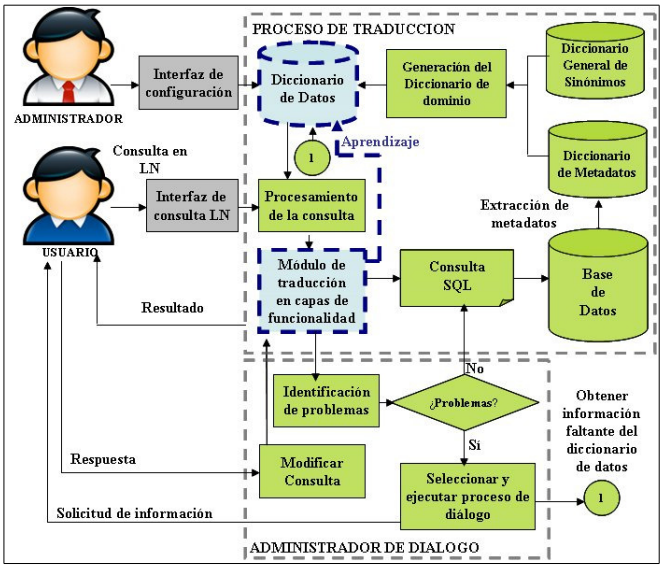

Figura 4. Arquitectura propuesta de la nueva ILNBD

En esta versión de la ILNBD, el proceso de traducción se comunica con el administrador de diálogo, el cual identifica el tipo de problema que tiene la consulta, basándose en la tipificación de problemas descrita en [8]. Si existe algún problema identificado, el administrador selecciona y ejecuta un proceso de diálogo que solicita información al usuario. Con la información recibida, modifica los datos de la consulta y la envía nuevamente al inicio del proceso de traducción. En caso de no existir ningún problema con la consulta, el proceso continúa de manera normal, y en caso contrario se inicia un nuevo proceso de diálogo. En la Figura 3, se muestra la arquitectura de la ILNBD con administrador de diálogo.

La tipificación realizada en esta versión abarca problemas de elipsis semántica; sin embargo, al realizar otro análisis en diversos corpus de consultas, además de encontrar que la mayoría de los problemas son de elipsis, fueron encontrados otros tipos de problemas, tales como el uso de palabras o sintagmas de diferentes categorías sintácticas para referirse a las tablas o columnas de la BD, la capacidad de cobertura de SQL, valores imprecisos (que son palabras que describen valores que pertenecen a un rango como tarde, pesado, etc.), entre otros, los cuales se describen en [9].

Debido a lo anterior, actualmente nos encontramos desarrollando una nueva versión de la ILNBD. En esta versión se contempla la implementación de un nuevo diccionario de datos (a partir en un modelo de BD concebido por nosotros), el cual está basado en la información necesaria para resolver los problemas descritos en [9]. Además de lo anterior, se ha diseñado una arquitectura basada en capas funcionales, en donde cada capa soluciona los problemas que se van encontrando durante el proceso de traducción. Adicionalmente, tanto el

diccionario de datos, como la arquitectura en capas soportarán las estructuras para aprender de la información que se obtiene mediante la interacción con el usuario a través del administrador de diálogo.

El nuevo diccionario de datos contiene información sobre palabras de diferentes categorías sintácticas, información estructural de la BD y estadísticas de aprendizaje que hacen referencia a tablas, columnas, relaciones, funciones de agregación, valores alias, valores imprecisos, etc. En [9] se encuentran los detalles del modelo en el que está basado el diccionario de datos.

A diferencia de las versiones anteriores, en esta versión se hace notar la separación entre el usuario del sistema y el administrador. Además, la generación automática del diccionario de datos crea sólo información referente a la estructura de la BD y algunas descripciones, por lo cual el administrador del sistema puede modificar o agregar más información. Este proceso es independiente del proceso realizado por el usuario final cuando realiza las consultas.

Anteriormente la ILNBD tenia tres fases en su módulo de traducción. Al integrar el nuevo diccionario de datos, se crearon capas funcionales que soportan la información para solucionar problemas que en versiones anteriores no se contemplaban. En [6, 9] se describen los problemas encontrados en consultas.

Las capas funcionales diseñadas para la nueva versión de la ILNBD corresponden a:

1. El manejo de valores imprecisos, que son clarificados mediante el administrador de diálogo en caso de no encontrarse en el diccionario de datos.

2. La identificación de tablas y columnas, donde se relacionan las tablas y las columnas con las palabras de diversas categorías gramaticales que se encuentran en la consulta.

3. La identificación de las frases Select y Where, donde se separan los requerimientos de las condiciones de búsqueda.

4. El manejo de la elipsis semántica, donde se clarifican los problemas de elipsis a través del administrador de diálogo.

5. La determinación de reuniones implícitas, en donde se establecen las relaciones entre las tablas que fueron encontradas en la consulta.

Las versiones anteriores alcanzan un porcentaje de éxito en la traducción entre el 79 % - 89 %; con la inclusión del nuevo diccionario de datos (basado en el modelo que hemos desarrollado), la arquitectura basada en capas y el método de aprendizaje esperamos obtener una tasa de éxito hasta de un 95 %.

Conclusiones

Las ILNBDs son herramientas de gran utilidad que facilitan la obtención de información contenida en BDs a través de consultas en LN. La exactitud de la información obtenida en estos sistemas es fundamental para la toma de decisiones; sin embargo, a pesar de su importancia y a la cantidad de sistemas desarrollados hasta la fecha, aún continúan existiendo muchas deficiencias. Los problemas encontrados son extremadamente complejos. Como ejemplo de las limitaciones encontradas, tenemos que incluso las ILNBDs comerciales han sido descontinuadas y el hecho de que ninguna se ha acercado al 100 % de consultas correctamente traducidas.

Para solucionar los problemas existentes hemos propuesto un nuevo diccionario de datos basado en un modelo de BDs que incluye información relevante para la correcta traducción de consultas en ILNBDs. Creemos que, para implementar un proceso de traducción exitoso, es necesaria una arquitectura basada en capas de funcionalidad (como las diseñadas en el modelo de comunicaciones OSI), donde cada capa funcional soluciona un problema y va refinando la información recibida. Con la inclusión de un método de aprendizaje, que obtenga información de la interacción con el usuario a través del administrador de diálogo, se espera alcanzar una tasa de éxito en la traducción cercana al 95 %. El aprendizaje obtenido será utilizado para modificar la información semántica contenida en el diccionario de datos implementado.

A pesar que desde hace varias décadas existe el desarrollo de este tipo de sistemas, el área de investigación sobre ILNBDs continúa abierta, por lo cual, es necesario identificar y evaluar cada uno de los tipos de problemas que se encuentran en el procesamiento de consultas para alcanzar un porcentaje de éxito aceptable en el proceso de traducción.✳

REFERENCIAS

1. Sethi V. (1986) "Natural Language Interfaces to Databases: MSI Impact, and Survey of their Use and Importance". University of Pittsburgh, 1986.

2. Cimiano P., Haase P., Heizmann J. (2007) "Porting Natural Language Interfaces Between Domains: an Experimental User Study with the ORAKEL System". En: Proc. 12Th International Conference on Intelligent User Interfaces. Honolulu, Hawaii, pp. 180–190

3. BBC News (2009) Bill Gates Says: Mouse is Out, Touch Screen and Natural Language Interface Are In. `http://news.bbc.co.uk/player/nol/newsid_7170000/newsid_7174300/7174330.stm?bw=bb&mp=wm&asb=1&news=1&bbcws=1` Recuperado en 23 de Junio de 2012.

4. Popescu A, Armanasu A, Etzioni O et al. (2004) "Modern natural language interfaces to databases: composing statistical parsing with semantic tractability". Proc. 20th International Conference on Computational Linguistics.

5. López V., Pasin M. y Motta E. (2005) "AquaLog: An Ontology-Portable Question Answering System for the Semantic Web". A. Gómez-Pérez and J. Euzenat (Eds.): ESWC 2005, LNCS 3532, Springer-Verlag, Berlin, Heidelberg 2005, pp. 546 -562.

6. Pazos R., González J., Aguirre M., Martínez J., Fraire H. (2012) "Natural Language Interfaces to Databases: An Analysis of the State of the Art". In Proc. International Seminar on Computational Intelligence 2012. Por aparecer en 2012.

7. Pazos R., Pérez J., et al. (2005) "A Domain Independent Natural Language Interface to Databases Capable of Processing Complex Queries". Lecture Notes in Artificial Intelligence, Vol. 3789. Springer-Verlag, pp. 833–842.

8. Pazos R., Rojas J., et al. (2010) "Dialogue Manager for a NLIDB for Solving the Semantic Ellipsis Problem in Query Formulation". Lecture Notes in Artificial Intelligence, Vol. 6277. Springer-Verlag, pp. 203–213.

9. Pazos R., Gonzalez J., Aguirre M. (2011) Semantic Model for Improving the Performance of Natural Language Interfaces. Proc. 10th Mexican International Conference on Artificial Intelligence Vol. 7094, pp. 277-290.

SOBRE LOS AUTORES

José Enrique Rojas Macedo recibió el título de Ingeniero de Software por la Universidad del Valle de México (UVM) en 2023, especializado en el desarrollo de aplicaciones móviles con Flutter, Google Cloud y Firebase. Motivado por empujar constantemente sus límites, contribución a causas sociales, compartir conocimiento y actualmente estudiando la Maestría en Ciencias de la Computación en la Universidad Autónoma del Estado de México. Sus intereses en investigación son el análisis de sentimientos, reconocimiento de patrones y minería de datos.

Ángel Hernández Castañeda recibió su Maestría y Doctorado en Ciencias de la Computación, con honores, por el Centro de Investigación en Computación (CIC) del Instituto Politécnico Nacional (IPN), en 2013 y 2017, respectivamente. Asimismo, es autor de diversas publicaciones en revistas internacionales de alto impacto. Actualmente es Profesor Investigador de Tiempo Completo en la Universidad Autónoma del Estado de México y miembro del Sistema Nacional de Investigadores (SNI) de México. Sus intereses en investigación incluyen el procesamiento de lenguaje natural, la minería de datos, el aprendizaje automático y el reconocimiento de patrones.